E9_22336216

人工智能实验

中山大学计算机学院

人工智能

本科生实验报告

（2023学年春季学期）

课程名称：Artificial Intelligence

教学班级	DCS315	专业（方向）	计算机科学与技术（系统结构）
学号	22336216	姓名	陶宇卓

1 实验题目

实验九：自然语言推理（Natural Language Inference）

一、算法原理

- **自然语言推理（Natural Language Inference）**

自然语言推理（Natural Language Inference，简称NLI），也称为文本蕴涵（Textual Entailment），是一项自然语言处理（NLP）任务，旨在判断给定的两个文本片段之间的推理关系。具体来说，给定一个前提（premise）和一个假设（hypothesis），NLI任务的目标是确定以下三种关系之一：

1. **蕴涵（Entailment）**：如果前提为真，那么假设也为真。例如：
    - 前提：所有的鸟都会飞。
    - 假设：麻雀会飞。 这里，假设从前提中可以推断出来，因此是蕴涵关系。
2. **不蕴涵（Contradiction）**：如果前提为真，那么假设为假。例如：
    - 前提：所有的鸟都会飞。
    - 假设：企鹅不会飞。 这里，假设和前提是相互矛盾的。
3. **中立（Neutral）（三分类特有）**：前提和假设之间既不支持也不矛盾。例如：
    - 前提：所有的鸟都会飞。
    - 假设：这只鸟是红色的。 这里，假设与前提无直接关系，既不能从前提推断出假设，也不会与前提矛盾。

NLI的应用

NLI在许多NLP应用中都起到了重要作用，包括但不限于：

- **问答系统**：通过推理用户问题与候选答案之间的关系，判断答案的正确性。
- **文本摘要**：通过推理摘要和原文之间的关系，验证摘要是否涵盖了原文的关键内容。
- **信息检索**：通过推理查询和文档之间的关系，筛选出与查询最相关的文档。

NLI模型

近年来，基于深度学习的NLI模型取得了显著进展，尤其是基于预训练语言模型（如BERT、RoBERTa、GPT等）的模型。这些模型通常通过以下步骤来解决NLI任务：

1. **编码器**：使用预训练语言模型将前提和假设编码为高维向量表示。
2. **拼接和交互**：将前提和假设的向量表示拼接或进行其他交互操作，以捕捉两者之间的关系。
3. **分类器**：使用全连接层和softmax激活函数，输出蕴涵、矛盾和中立的概率。

- Bi-LSTM

LSTM是一种改进的循环神经网络（RNN），旨在解决RNN中的长期依赖问题。LSTM通过引入门控机制（输入门、遗忘门、输出门）来控制信息的流动，从而能够更好地捕捉序列中的长时依赖关系。

LSTM单元的核心组件：

- **遗忘门（Forget Gate）**：控制前一时间步的记忆内容是否保留。
- **输入门（Input Gate）**：控制当前时间步的新信息是否写入记忆。
- **输出门（Output Gate）**：控制当前时间步的记忆内容如何输出。

双向LSTM结构

双向LSTM由两个独立的LSTM网络组成，一个处理输入序列的正向（从前到后），另一个处理反向（从后到前）。通过结合这两个方向的信息，双向LSTM能够更全面地理解序列数据的上下文信息。

双向LSTM的结构示意图：

`输入序列: x1, x2, ..., xn`

`正向LSTM: h1_forward, h2_forward, ..., hn_forward`

`反向LSTM: h1_backward, h2_backward, ..., hn_backward`

`双向LSTM输出: [h1_forward, h1_backward], [h2_forward, h2_backward], ..., [hn_forward, hn_backward]`

算法原理

1. **输入序列**：
   - 输入序列 (x1,x2,...,xn)(x_1, x_2, ..., x_n)(x1,x2,...,xn) 同时送入正向和反向LSTM网络。
2. **正向传播**：
   - 正向LSTM按照时间顺序（从 x1x_1x1 到 xnx_nxn）处理输入序列，计算每个时间步的隐藏状态。
3. **反向传播**：
   - 反向LSTM按照时间逆序（从 xnx_nxn 到 x1x_1x1）处理输入序列，计算每个时间步的隐藏状态。
4. **隐藏状态拼接**：
   - 将正向LSTM和反向LSTM在每个时间步的隐藏状态拼接，形成双向LSTM的输出。
5. **输出层**：
   - 双向LSTM的输出可以连接到后续的全连接层、输出层或其他网络层，用于特定任务（如分类、预测等）。

优点

- **更全面的上下文信息**：
  - 双向LSTM能够同时考虑每个时间步的前后文信息，适用于需要捕捉全局依赖的任务。
- **改进的性能**：
  - 在许多自然语言处理任务（如文本分类、机器翻译等）中，双向LSTM通常比单向LSTM表现更好。

- **具体实现**

1. 数据读取

数据读取是NLI任务的第一步，需要读取包含前提（premise）和假设（hypothesis）对的标注数据集。在QNLI任务中，前提通常是句子，而假设是一个问题。目标是判断前提和假设之间的关系是否存在。

- **数据集格式**：QNLI数据集包含三列：ID、句子（Sentence）、问题（Question）和标签（Label）。标签指示问题和句子是否匹配（即句子是否回答了问题）。

2. 数据预处理

在数据预处理阶段，数据需要进行清洗和格式化，以便后续处理。

- **文本清洗**：去除特殊字符等噪音数据。
- **标记化（Tokenization）**：将文本划分为单词或子词单元。使用标准的NLP库如NLTK或SpaCy进行标记化。
- **映射标签**：将标签（如"entailment"和"not_entailment"）映射到数值，如0和1。

3. 词嵌入（Embedding）

词嵌入是将文本中的单词映射到高维向量空间中，以捕捉词汇的语义信息。

- **加载GloVe**：从预训练的GloVe嵌入文件（如glove.6B.300d.txt）中加载词嵌入。每个单词将映射到一个固定大小的向量（如300维）。
- **创建嵌入矩阵**：构建一个嵌入矩阵，矩阵的每一行对应一个词的GloVe向量。如果数据集中某些词在GloVe中不存在，可以随机初始化这些词的嵌入向量，或者直接初始化向量为零向量。

4. 数据对齐（Padding）

由于不同的句子长度不一致，需要对齐（padding）以便批处理。

- **固定长度**：设定最大序列长度，超过该长度的句子进行截断，不足的句子进行填充（padding），通常填充零。

5. 使用分类模型进行训练

使用深度学习分类模型对处理后的数据进行训练，以预测前提和假设之间的关系。

- **模型架构**：
  - **输入层**：接受前提和假设的嵌入向量。
  - **嵌入层**：使用预加载的GloVe嵌入矩阵，将输入单词索引映射到词向量。

    - **编码层**：使用双向LSTM对前提和假设的嵌入进行编码。LSTM的隐藏状态可以捕捉序列中的上下文信息。
    - **拼接层**：将前提和假设的编码表示拼接起来。
    - **全连接层**：将拼接后的表示传递给全连接层，进行分类。
    - **输出层**：使用softmax激活函数输出两类的概率。
- **训练步骤**：
    - **输入编码**：将前提和假设输入编码为向量表示。
    - **前向传播**：将输入向量传递给模型，计算输出。
    - **损失函数**：使用交叉熵损失函数计算预测结果与真实标签之间的误差。
    - **反向传播**：计算梯度并更新模型参数，以最小化损失函数。
- **超参数调整**：调整学习率、批量大小等超参数，以优化模型性能。

6. 输出分析

训练完成后，对模型进行评估和分析，以了解其性能和改进方向。

- **评估指标**：使用准确率、loss值等指标评估模型性能。

- **流程图**

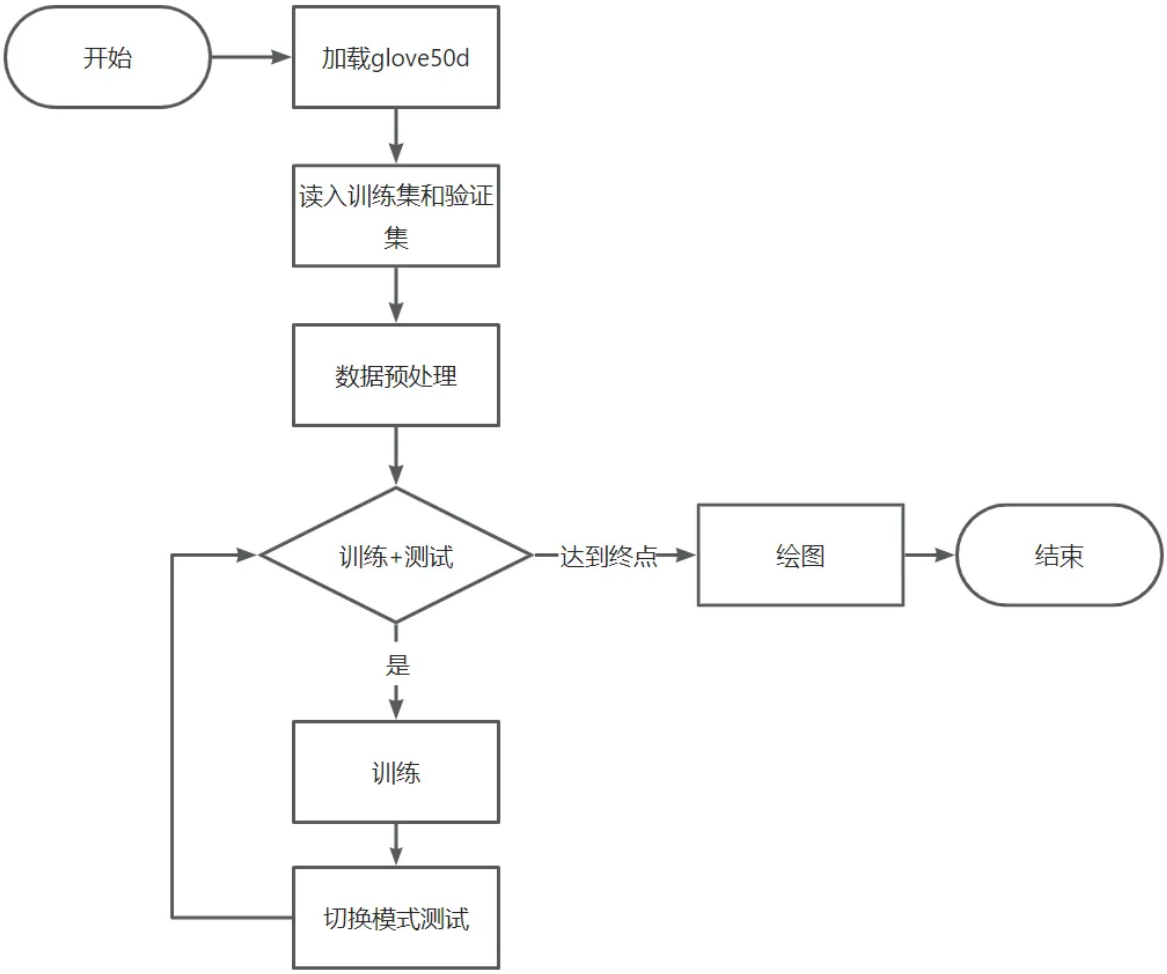

二、伪代码

```
定义 preprocess_data 函数:
    读取并处理数据
    参数:
        文件路径
        句子最大长度
        词嵌入模型
    步骤:
        初始化句子和标签列表
        读取文件中的数据
        获取英语停用词列表
        遍历数据中的每一行:
            对问题和句子进行分词
            合并并处理分词结果，排除停用词，限制句子长度
            将单词转换为词向量，若单词不在词嵌入模型中则用零向量代替
            对齐句子长度，填充零向量
            将处理后的句子和标签添加到对应列表中
    返回值:
        处理后的句子和标签列表

# LSTM模型类
定义 LSTMModel 类:
    初始化函数:
        构建双向LSTM层，指定输入维度、隐藏层维度、层数
        构建全连接层，指定输出维度
        构建Dropout层
    前向传播函数:
        初始化LSTM层的隐藏状态和细胞状态
        进行LSTM前向传播
        获取最后时间步的输出
        通过全连接层并进行Dropout
        返回输出

# 训练函数
定义 train 函数:
    模型切换到训练模式
    初始化损失值、正确预测数和总数
    遍历数据加载器中的每个批次:
        获取输入和标签
        梯度清零
        进行前向传播，计算输出
        计算损失
```

```
            反向传播，更新模型参数
            累加损失值和正确预测数
        计算每个epoch的平均损失和准确率
        返回平均损失和准确率

# 评估函数
定义 evaluate 函数:
    模型切换到评估模式
    初始化损失值、正确预测数和总数
    禁用梯度计算:
        遍历数据加载器中的每个批次:
            获取输入和标签
            进行前向传播，计算输出
            计算损失
            累加损失值和正确预测数
    计算每个epoch的平均损失和准确率
    返回平均损失和准确率

# 训练QNLI模型函数
定义 train_qnli_model 函数:
    参数:
        训练文件
        验证文件
        句子最大长度
        批次大小
        词嵌入模型
        训练轮数
    步骤:
        调用 preprocess_data 函数处理训练和验证数据
        创建训练和验证数据集
        初始化数据加载器，指定批次大小
        打印训练和验证样本数量
        初始化模型参数:
            输入维度
            隐藏层维度
            层数
            输出维度
        初始化LSTM模型
        定义损失函数为交叉熵损失
        定义优化器为Adam
        初始化损失和准确率列表
        训练多个epoch:
            记录开始时间
            调用 train 函数进行训练，获取训练损失和准确率
```

```
86                  调用 evaluate 函数进行评估，获取验证损失和准确率
87                  记录结束时间
88                  打印当前epoch的训练和验证损失、准确率及时间
89                  记录损失和准确率
90          返回训练和验证的损失、准确率
```

三、关键代码展示

> 完整代码见../code

- 数据预处理函数preprocess_data

```python
def preprocess_data(file_path, max_length, embedding_model):
    """
    函数功能：一体化数据处理。读取数据，对数据进行预处理，词嵌入和数据对齐
    :param file_path: 文件路径
    :param max_length: 句子最大长度 --> 对于整个数据集，我们将所有句子都填充或截断到相同的长度60，再大可能会使数组过大而报错
    :param embedding_model: 词嵌入模型
    """
    sentences = []
    labels = []
    embedding_dim = len(embedding_model[next(iter(embedding_model.keys()))])

    df = pd.read_csv(file_path, sep='\t', header=0, on_bad_lines='skip')

    stop_words = set(stopwords.words('english'))  # 获取英语停用词列表
    for _, row in df.iterrows():
        question = nltk.word_tokenize(row['question'])
        hypothesis = nltk.word_tokenize(row['sentence'])
        sentence = question + hypothesis # 不做任何处理
        # sentence = [word.lower() for word in question + hypothesis]  # 转小写
        # sentence = [word for word in question + hypothesis if word.isalpha()]  # 去掉标点符号
        # sentence = [word for word in question + hypothesis if word.isalpha() and word not in stop_words]
        # sentence = [word.lower() for word in question + hypothesis if word not in stop_words]  # 排除停用词1
        sentence = sentence[:max_length]

        sentence_vectors = [embedding_model[word] if word in embedding_model else np.zeros(embedding_dim) for word in sentence]

        while len(sentence_vectors) < max_length:
            sentence_vectors.append(np.zeros_like(sentence_vectors[0]))
        sentences.append(np.array(sentence_vectors, dtype='float32'))
        labels.append(int(row['label'] == 'entailment'))

    return sentences, labels
```

- 定义Bi-LSTM

```python
class LSTMModel(nn.Module):
    def __init__(self, input_dim, hidden_dim, output_dim, n_layers):
        super(LSTMModel, self).__init__()
        self.lstm = nn.LSTM(input_dim, hidden_dim, num_layers=n_layers, bidirectional=True, batch_first=True)
        self.fc = nn.Linear(hidden_dim * 2, output_dim)
        self.dropout = nn.Dropout(0.5)

    def forward(self, x):
        h0 = torch.zeros(self.lstm.num_layers * 2, x.size(0), self.lstm.hidden_size).to(x.device)
        c0 = torch.zeros(self.lstm.num_layers * 2, x.size(0), self.lstm.hidden_size).to(x.device)
        h_lstm, _ = self.lstm(x, (h0, c0))
        h_lstm = h_lstm[:, -1, :]
        out = self.fc(h_lstm)
        out = self.dropout(out)
        return out

```

- 训练函数

```python
def train_qnli_model(train_file, valid_file, max_length, batch_size, embedding_model, num_epochs):
    embedding_dim = len(embedding_model[next(iter(embedding_model.keys()))])

    train_sentences, train_labels = preprocess_data(train_file, max_length, embedding_model)
    valid_sentences, valid_labels = preprocess_data(valid_file, max_length, embedding_model)

    train_dataset = list(zip(train_sentences, train_labels))
    valid_dataset = list(zip(valid_sentences, valid_labels))

    train_loader = DataLoader(train_dataset, batch_size=batch_size, shuffle=True)
    valid_loader = DataLoader(valid_dataset, batch_size=batch_size, shuffle=False)

    print('Number of training samples:', len(train_dataset))
    print('Number of validation samples:', len(valid_dataset))

    input_dim = embedding_dim
    hidden_dim = 128
    n_layers = 2
    output_dim = 2

    model = LSTMModel(input_dim, hidden_dim, output_dim, n_layers)
    criterion = nn.CrossEntropyLoss()
    optimizer = optim.Adam(model.parameters(), lr=0.0001)

    loss = []
    accuracy = []

    for epoch in range(num_epochs):
        start_time = time.time()
        train_loss, train_acc = train(model, train_loader, criterion, optimizer)
        valid_loss, valid_acc = evaluate(model, valid_loader, criterion)
        end_time = time.time()

```

```
        print('Epoch:', epoch + 1)
        print('Training Loss:', train_loss, 'Training Accuracy:', train_acc)
        print('Validation Loss:', valid_loss, 'Validation Accuracy:', valid_acc)
        print('Time per epoch:', end_time - start_time, 'seconds')

        loss.append((train_loss, valid_loss))
        accuracy.append((train_acc, valid_acc))

    return loss, accuracy
```

- 主函数

```python
def main():
    # 定义训练集和验证集文件路径
    train_file = '../train_40.tsv'
    valid_file = '../dev_40.tsv'

    # 定义句子最大长度和批次大小
    max_length = 50
    batch_size = 32
    num_epochs = 10

    # 加载GloVe词向量模型
    embedding_model = {}
    with open('E:\glove.6B\glove.6B.50d.txt', 'r', encoding='utf-8') as f:
        for line in f:
            values = line.strip().split()
            word = values[0]
            vector = np.array(values[1:], dtype='float32')
            embedding_model[word] = vector
    embedding_dim = len(embedding_model[next(iter(embedding_model.keys()))])

    loss, accuracy = train_qnli_model(train_file, valid_file, max_length, batch_size, embedding_model, num_epochs)
    train_loss, valid_loss = zip(*loss)
    train_acc, valid_acc = zip(*accuracy)

    plot_curves(train_loss, train_acc, valid_loss, valid_acc)
```

四、创新点&优化

- **数据预处理的综合性**：

代码中预处理数据函数preprocess_data，对数据进行了分词、去停用词、词向量化以及对齐等一系列操作。这种综合性的预处理能提高数据的质量，进而提升模型的性能。

同时，与其他需要多个函数进行数据预处理的代码形式相比，一个函数封装更有代码可读性，更规范。

- **双向LSTM网络结构**：

使用双向LSTM网络（self.lstm = nn.LSTM(..., bidirectional=True)），能从两个方向捕捉序列信息，有助于提高模型对文本的理解和预测能力。

3 实验结果及分析

1. 实验结果展示，评测指标分析

因为本人的电脑没有N卡，所以一轮训练和测试就要大约4-6分钟。因此epoch没有太大，定为10。

对以下预处理方式进行了多次测试，结果如下：

不做处理：

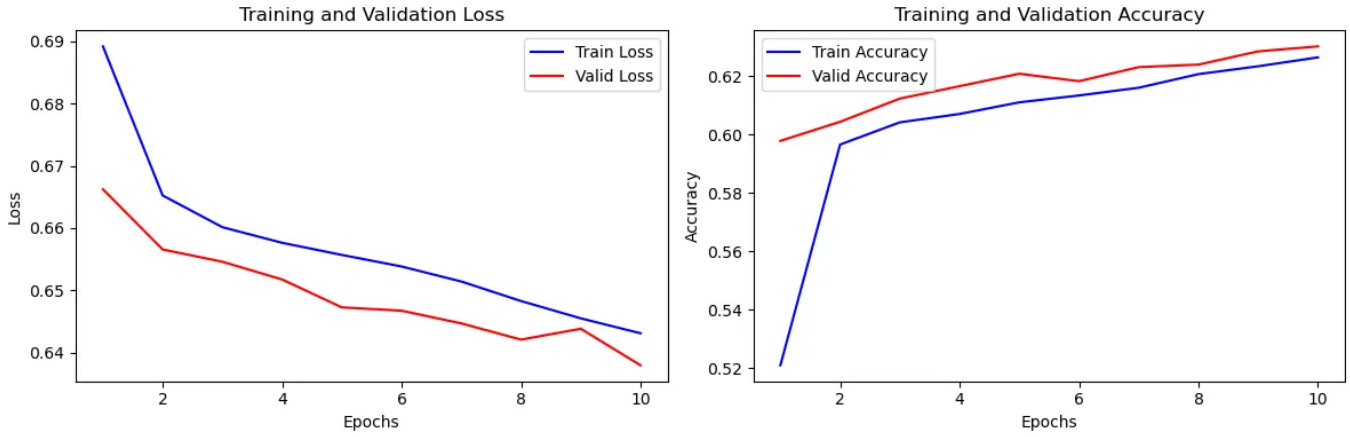

去掉停用词：

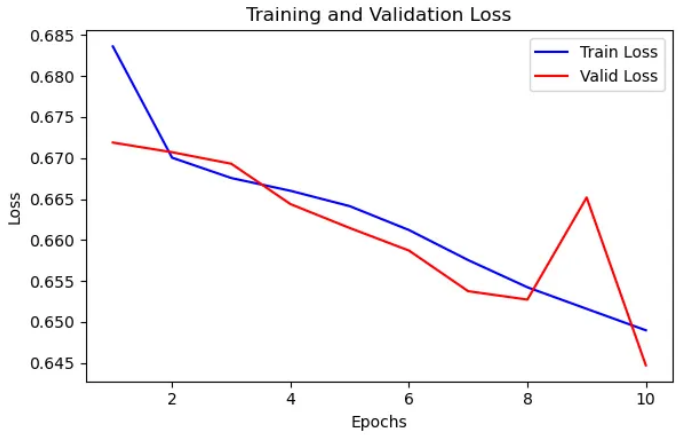

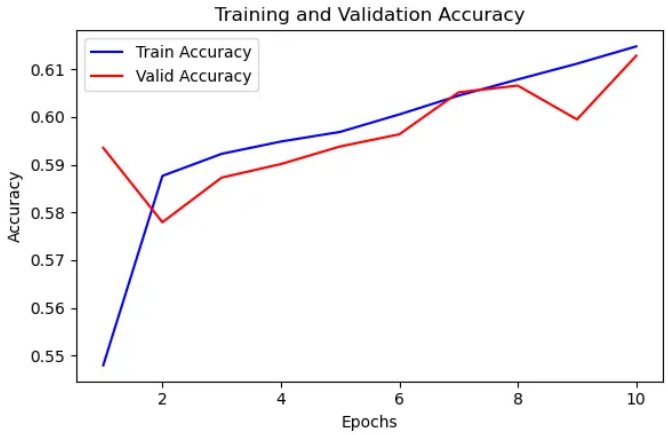

转小写：

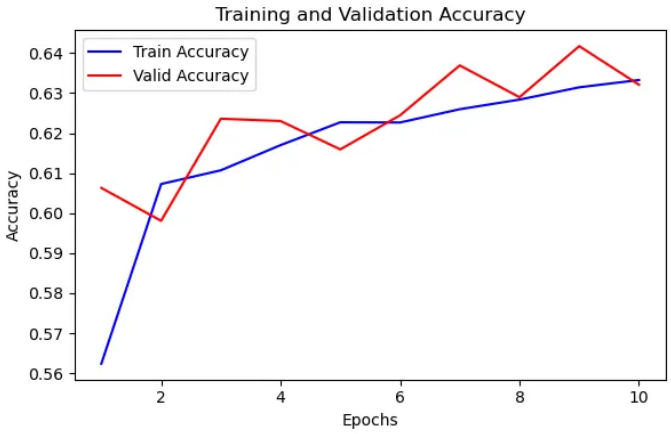

去掉标点和停用词：

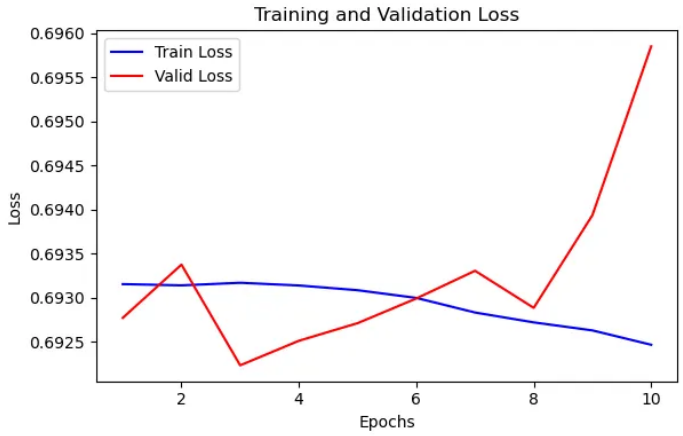

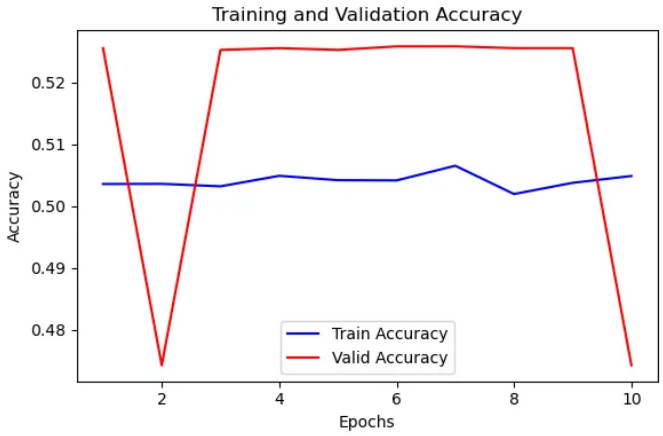

去标点：

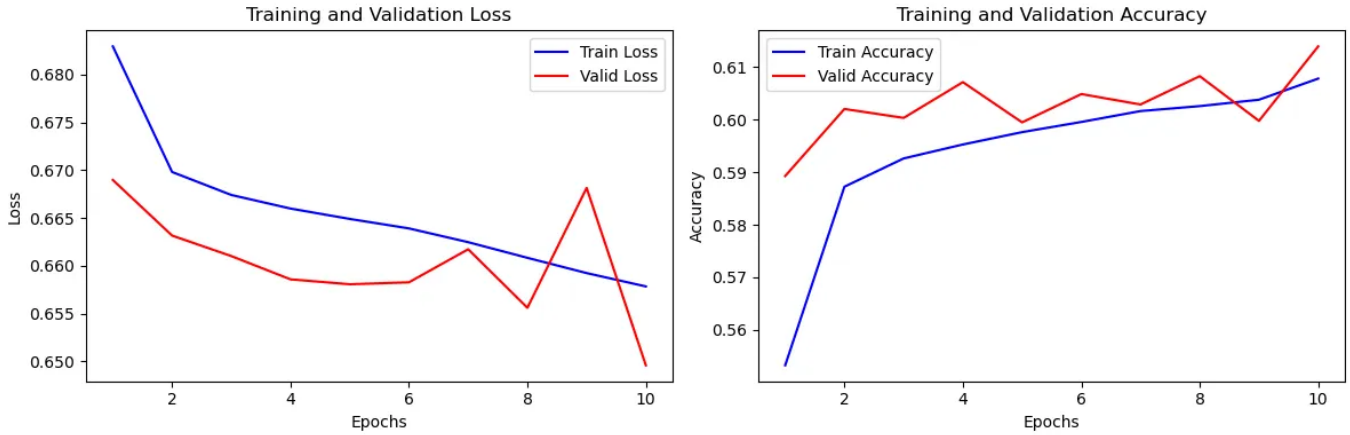

汇总如下：

类型	不做处理	去掉停用词	转小写	去掉标点和停用词	去掉标点
最大准确率	62.5%	61.3%	64.2%	52.7%	61.4%
波动情况	稳定	略微波动	略微波动	明显波动	略微波动
loss是否收敛	是	是	是	否	是

需要说明的是，因为运行一次程序所需时间对于我来说过长，所以我没有进行很多次的测试取最好结果。所以此结果只能说非常粗略。

但是可以确定的是，去掉标点符号的效果一定不算很好，因为glove词汇表里是有诸如逗号引号这样的标点的，去掉了反而不利于体现句子整体语义，去掉停用词导致效果变差的原因如下：

- **语义信息丢失：**虽然停用词（如 "the", "is", "at"）在很多情况下不携带重要的语义信息，但在某些上下文中，它们可能对理解句子的含义至关重要。同样，标点符号也可以携带语义信息，例如，问号可能表示一个句子是一个问题。
- **语境信息丢失：**在某些情况下，即使单个词可能不携带很多信息，但是词与词之间的关系可能非常重要。例如，在否定句中，"not" 后面的词可能会改变句子的整体含义。

另外，在我的实验结果里，词汇转小写的最大准确率要更好，而不做任何处理所训练出来得到的结果没有过拟合，也没有明显波动。原因可能如下：

- **减少词汇表大小：**如果不进行大小写转换，那么同一个词语的大小写形式会被视为两个不同的词语。这会导致词汇表的大小增加，从而增加模型的复杂性和训练难度。通过转化为小写，我们可以有效地减少词汇表的大小。

- **提高数据稀疏性：**在自然语言处理中，数据稀疏性是一个常见的问题。如果我们将大小写视为不同的词语，那么一些词语可能只在某些特定的情况下（例如句首）以大写形式出现，这会导致这些词语的出现次数变少，从而增加数据的稀疏性。通过转化为小写可以有效地减少数据的稀疏性。
- **消除噪声：**在一些情况下，词语的大小写形式可能会受到打字错误或其他非语言因素的影响。将所有的词语转化为小写可以消除这些噪声，从而提高模型的准确性。

时空复杂度分析：

- **时间复杂度**：

假设数据集有 N 行，每行的最大长度为 L，词嵌入的维度为 D。

- 读取和处理数据：需要遍历每一行，处理每个单词。时间复杂度为 O(N×L)。
- 分词和去停用词：假设分词和去停用词操作的时间复杂度为 O(L)，那么总的时间复杂度也是 O(N×L)。
- 词向量转换：对每个单词查找词向量，时间复杂度为 O(L×D)，总的时间复杂度为 O(N×L×D)。

综上，数据预处理的总时间复杂度为 O(N×L×D)。

- **空间复杂度**：
- 存储数据：需要存储处理后的数据，每个句子的长度为 L，词嵌入的维度为 D，总空间复杂度为 O(N×L×D)。

总体空间复杂度为 O(N×L×D)。

4 思考题

无

5 参考资料

实验课PPT

基于pytorch构建双向LSTM（Bi-LSTM）文本情感分类实例（使用glove词向量）_pytorch实现基于双向lstm模型完成文本分类任务-CSDN博客

glove使用以及词表文件详解——小白必看，通俗易懂_glove.6b-CSDN博客